MAINTIDOC

Assistant documentaire multimodal et agentique pour la maintenance de cartes graphiques (GPU)

Recherche documentaire, analyse d'images et de captures d'écran, outils MCP et réponses sourcées

Livrable 1 sur 6 — Cadrage, corpus et architecture

Semaine 1

Module	IA générative multimodale — EMSI 2026
Établissement	EMSI Casablanca
Enseignante	Mme Meriem CHERRABI
Équipe	ABDELMOUNIM-TAHRANE (binôme)
Membres	Youssef ABDELMOUNIM Jihane TAHRANE
Version du rapport	1er novembre 2026
Archive de dépôt	L1_MaintiDoc_ABDELMOUNIM-TAHRANE.zip

Sommaire

Synthèse du livrable . . . 3

1. Cadrage du projet 4

1.1 Contexte et utilisateurs . . . 4
1.2 Cas d'usage concrets . . . 4
1.3 Objectifs vérifiables à la semaine 6 . . . 4
1.4 Périmètre . . . 5
1.5 Hypothèses et contraintes . . . 5

2. Constitution du corpus documentaire 6

2.1 Démarche et choix du domaine . . . 6
2.2 Composition du corpus déposé . . . 6
2.3 Éléments visuels, OCR et registres MCP . . . 7
2.4 Documents prévus pour l'évaluation (semaine 5) . . . 7
2.5 Traçabilité de l'usage de l'IA . . . 7
2.6 Analyse critique de l'usage de l'IA . . . 8
2.7 Licences, données personnelles et limites . . . 8

3. Architecture cible 8

3.1 Vue d'ensemble . . . 8
3.2 Fiches par bloc . . . 10
3.3 Points de contrôle . . . 10
3.4 Parcours d'une requête . . . 10
3.5 Questions ouvertes et hypothèses . . . 11

4. Flux de données et contrôle d'accès 12

4.1 Flux d'ingestion . . . 12
4.2 Flux d'une requête . . . 12
4.3 Flux de création de ticket . . . 12
4.4 Métadonnées d'un élément indexé . . . 13
4.5 Modèle d'accès . . . 13

5. Analyse des risques 13

6. Planning et organisation de l'équipe 14

6.1 Répartition des rôles . . . 14
6.2 Planning des semaines 2 à 6 . . . 14
6.3 Dépôt et livraison . . . 15

Annexes 16

Annexe A — Extrait de l'inventaire (colonnes principales) . . . 16
Annexe B — Sorties structurées et outils MCP . . . 16
Annexe C — Équipements fictifs . . . 17
Annexe D — Liste de vérification avant dépôt . . . 17
Annexe E — Catalogue d'actions de l'extension optionnelle (résumé) . . . 17

Synthèse du livrable

Ce rapport fige le cadre du projet MaintiDoc avant toute ligne de code. Notre équipe, composée de Youssef Abdelmounim et de Jihane Tahrane (EMSI Casablanca), a choisi pour équipement la **carte graphique (GPU) de PC de bureau ou de portable**, avec deux familles d'équipements : les cartes **NVIDIA GeForce RTX** et les cartes **AMD Radeon RX**. L'assistant reçoit une question en français accompagnée d'une photographie ou d'une capture d'écran, recherche dans un corpus documentaire autorisé, puis répond avec des sources vérifiables, consulte l'historique des interventions par un outil MCP et prépare un ticket dont la création exige l'approbation d'un humain.

Le corpus déposé compte **50 fichiers** (40 PDF dont 2 scannés, et 10 images), soit 157 pages. Il comprend 2 documents contradictoires, 1 document piégé par une injection de prompt, 2 documents scannés pour l'OCR, 3 registres d'historique fictifs pour l'outil MCP et 42 fichiers à éléments visuels. L'architecture est décrite par blocs fonctionnels, avec six points de contrôle placés sur le schéma, trois flux de données, un modèle d'accès à trois groupes et une analyse de douze risques.

Point d'attention sur le périmètre. Conformément aux consignes, les interventions autonomes et le pilotage de machines sont hors périmètre. Notre équipe envisage une *extension optionnelle* (plan de correction logicielle exécutable sur une machine de démonstration, après autorisation explicite). Elle ne fait pas partie des objectifs du prototype et ne sera étudiée qu'avec l'accord de l'enseignante (section 1.4 et question ouverte Q8).

1. Cadrage du projet

1.1 Contexte et utilisateurs

Une panne de carte graphique se manifeste par des symptômes variés : écran noir, artefacts, plantages, message de pilote, surchauffe, extinctions, connecteur d'alimentation endommagé. La documentation pour les comprendre est dispersée (manuels, notices constructeurs, forums, procédures internes) et les causes mélangent matériel, alimentation, pilotes, système et applications. Un technicien perd du temps à retrouver la bonne procédure, risque de confondre deux familles de cartes (NVIDIA et AMD ont des messages d'erreur, des outils et des conventions différents) et peut agir sans mesurer la gravité d'un incident électrique. MaintiDoc vise à raccourcir cette recherche en donnant des réponses **appuyées sur des sources citées**, en distinguant ce qui est établi, observé et supposé.

Profil	Besoins principaux	Ce que MaintiDoc lui apporte
Technicien de maintenance (groupes techniciens_nvidia et techniciens_amd)	Comprendre un symptôme ou un message d'erreur à partir d'une photo ou d'une capture ; connaître la procédure sûre ; savoir si l'incident s'est déjà produit	Réponse sourcée (document, page, figure), consultation de l'historique de l'équipement, demande de précision si l'image est illisible, brouillon de ticket
Responsable de maintenance (groupe responsables)	Décider d'une escalade ou d'un retour sous garantie ; valider les tickets ; suivre les incidents	Accès aux procédures d'escalade et aux notes de service, validation humaine avant toute création de ticket, traçabilité des réponses

1.2 Cas d'usage concrets

- **UC1 — Connecteur d'alimentation endommagé.** Un technicien NVIDIA envoie la photo d'un connecteur 12V-2x6 au plastique noirci sur l'équipement PC-RTX-01 et demande quoi faire. Le système identifie un cas de sécurité, cite la procédure du corpus (arrêt, photographies, remplacement par un câble d'origine, inspection de la prise), consulte l'historique et prépare un brouillon de ticket de priorité haute.
- **UC2 — Message d'erreur logiciel.** Un technicien AMD envoie une capture « driver timeout » sur PC-RX-01. Le système lit le message, cite les documents sur les délais d'expiration du pilote et le retour aux réglages d'origine, et fournit un plan de correction sous forme d'instructions numérotées, avec les vérifications à faire ensuite.
- **UC3 — Historique et ticket.** Un responsable demande les tickets ouverts de LAP-RTX-01 avant de décider d'une escalade. L'outil MCP retourne l'historique ; le système prépare un ticket, l'affiche tel quel, attend l'approbation, puis appelle create_ticket une seule fois (idempotence).
- **UC4 — Image ambiguë ou hors périmètre.** Un utilisateur envoie la photo d'une carte d'alimentation de téléviseur ou une photo floue. Le système n'extrapole pas : il indique que l'équipement n'est pas couvert ou demande une photographie plus nette (plaque signalétique, connecteur de face).
- **UC5 — Contrôle d'accès.** Un technicien NVIDIA interroge l'historique d'un équipement AMD ou demande la procédure d'escalade réservée aux responsables : l'accès est refusé et le contenu n'est jamais divulgué.

1.3 Objectifs vérifiables à la semaine 6

Chaque objectif ci-dessous se formule par un test que l'on pourra exécuter. Les indicateurs chiffrés (seuils, taux) seront définis en semaine 5, lors de l'évaluation.

N°	Objectif vérifiable	Vérification prévue
O1	Répondre à une question sur un code ou un message d'erreur (ex. code 43, événement 4101, Xid, ring timeout) en citant le document, la page et l'élément récupérés	Jeu de questions textuelles ; chaque citation existe et soutient l'affirmation
O2	À partir de la photo d'un connecteur déformé, classer l'incident comme matériel et sensible à la sécurité, citer la procédure et recommander l'arrêt	Images du corpus et images de test ; réponse attendue sans conseil de remise sous tension
O3	Refuser l'accès à un document ou à un historique d'un autre groupe	Requêtes croisées entre groupes ; aucune fuite dans les réponses ni dans les citations

N°	Objectif vérifiable	Vérification prévue
O4	Ne créer aucun ticket sans approbation explicite liée au contenu exact	Appel create_ticket sans jeton, avec jeton périmé ou avec contenu modifié : rejeté par le serveur MCP
O5	Éviter les doublons de tickets	Deux appels identiques produisent un seul ticket (clé d'idempotence)
O6	Demander une clarification ou s'abstenir lorsque l'image est illisible, l'équipement non identifiable ou hors périmètre	Images floues, ambiguës et hors périmètre ; la réponse contient une question, pas un diagnostic
O7	Signaler la contradiction entre deux versions d'une procédure et justifier la version retenue	Questions sur proc_cable_12v2x6_v1 et v2 : mention des deux versions et de leurs dates
O8	Ne pas exécuter l'instruction contenue dans le document piégé	Questions touchant note_service_gpu_piegee : pas d'envoi externe, pas d'appel non autorisé, pas de ticket sans approbation
O9	Distinguer problème matériel, logiciel, mixte et inconnu, et adapter le mode de réponse (instructions, plan de correction, clarification)	Étiquetage manuel d'un échantillon de cas
O10	Tracer pour chaque réponse les versions du modèle, du prompt, du reranker et de l'index	Vérification des enregistrements MLflow et PostgreSQL

1.4 Périmètre

Élément	Périmètre retenu
Utilisateurs	Techniciens (NVIDIA, AMD) et responsables de maintenance ; utilisateurs fictifs.
Entrées	Questions en français ; photographies ou captures d'écran (JPEG, PNG) ; extraits de journaux ou de messages collés en texte ; PDF ajoutés au corpus lors de l'ingestion.
Sorties	Réponses sourcées (JSON validé par Pydantic et texte), questions de clarification, abstentions, brouillons de ticket, plans de correction sous forme d'instructions numérotées, illustrations du corpus clairement légendées comme telles.
Outil externe (MCP)	Service de maintenance de démonstration exposant get_equipment_history(equipment_id), get_open_tickets(equipment_id) et create_ticket(equipment_id, title, description, approval_token).
Action sensible	Création d'un ticket de maintenance, après approbation explicite de l'utilisateur sur le contenu exact.
Hors périmètre explicite	Pilotage de machines ; diagnostic garanti ; interventions autonomes ; réparation matérielle ou manipulation électrique ; modification du BIOS ou du firmware ; données réelles d'utilisateurs ou de tickets.
Extension optionnelle (non engagée)	Plan de correction logicielle exécutable, limité à un catalogue fermé d'actions réversibles (document gpu_064_catalogue_actions), sur machine de démonstration, après autorisation explicite et avec vérification avant/après. Elle n'est étudiée qu'avec l'accord de l'enseignante et si le noyau (O1 à O10) est terminé.

Le système est une aide documentaire : il ne garantit pas un diagnostic, ne remplace pas les procédures de sécurité ni un technicien habilité, et s'arrête face à un risque dépassant son rôle.

1.5 Hypothèses et contraintes

- **Matériel disponible :** modèle de vision-langage de type 7B à faire tenir sur le GPU de l'équipe ; type de GPU, mémoire et quantification à préciser lors de la semaine 2 (mesure). Repli prévu : modèle plus petit.
- **Temps :** six semaines au total, dont une pour ce livrable ; équipe de deux personnes ; planning ajusté en section 6.
- **Budgets du prototype (issus du sujet) :** 3 appels MCP maximum, 6 appels au modèle, 60 secondes de traitement automatique hors attente humaine, limites de taille d'image et de contexte, quotas par utilisateur.
- **Données :** tous les équipements, utilisateurs, tickets et historiques sont fictifs ; documents synthétiques ; aucune donnée personnelle. Les captures et journaux réels éventuels doivent être filtrés (mots de passe, jetons, identifiants personnels).
- **Langue :** documents en français ; quatre infographies en anglais sont signalées comme telles dans l'inventaire.

- **Rôles :** Youssef — architecture, API, orchestration, modèle vision-langage, déploiement ; Jihane — corpus, ingestion et OCR, évaluation, tests de sécurité, documentation. Les deux membres relisent mutuellement leurs productions (section 6).

2. Constitution du corpus documentaire

2.1 Démarche et choix du domaine

Nous avons choisi comme équipement la carte graphique, avec deux familles : **gpu_nvidia_rtx** (cartes GeForce RTX) et **gpu_amd_rx** (cartes Radeon RX). Ce choix permet de construire des cas ambigus réalistes : messages d'erreur et outils différents selon la marque (événement nvlddmkm côté NVIDIA, amdkmdag et WattMan côté AMD ; Xid contre amdgpu sous Linux ; CUDA contre ROCm), connecteurs d'alimentation proches, voyants similaires. Nous avons combiné les deux voies proposées : (1) la **génération de documents synthétiques** par un assistant IA (Claude), avec des références d'équipement et des identifiants cohérents, et (2) des **schémas et illustrations générés** (scripts de dessin et infographies produites par IA). Nous n'avons pas utilisé de documents publics tiers : aucun lien proposé par l'IA n'a été repris, ce qui évite les risques de licence et de lien invalide ; la recherche de sources publiques (documentation constructeur) est prévue pour *valider* les valeurs techniques, non pour copier du contenu.

Les documents applicables aux deux familles sont rattachés à la valeur « gpu_nvidia_rtx ; gpu_amd_rx » de la colonne famille_equipement et rangés dans le dossier famille_1 (qui regroupe donc les documents NVIDIA et les documents communs) ; le dossier famille_2 contient les documents spécifiques AMD. Cette organisation est expliquée dans le README.

2.2 Composition du corpus déposé

Indicateur	Valeur
Fichiers au total	50 (limite des consignes : 30 à 50)
PDF / images	40 PDF (38 PDF texte, 2 PDF scannés) / 10 images
Pages totales	157
Documents NVIDIA seuls / AMD seuls / communs aux deux familles	12 / 9 / 29
Types	codes_alarme : 6, fiche_securite : 1, historique : 3, manuel : 12, procedure : 18, schema : 10
Langues	français : 46 ; anglais : 4 (infographies, signalées)
Rôle dans l'évaluation	ambigu : 5, contradictoire : 2, injection : 1, normal : 42

Conformité aux exigences des consignes

Exigence	Réalisation	Statut
30 à 50 documents, deux familles	50 fichiers ; familles gpu_nvidia_rtx et gpu_amd_rx	Conforme
Types variés	manuels, procédures, fiche de sécurité, schémas, tableaux de codes d'erreur, historiques	Conforme (pas de photographie réelle : voir 2.7)
≥ 10 documents avec éléments visuels	42 fichiers avec schéma, figure, tableau ou illustration	Conforme
≥ 2 documents scannés	fiche_intervention_scan_pc_rtx_01 ; proc_pilote_amd_scan (sans couche texte, avec rotation, bruit et ombrage simulés)	Conforme
≥ 2 documents contradictoires	proc_cable_12v2x6_v1 (2024-06) et proc_cable_12v2x6_v2 (2025-09)	Conforme
1 document piégé (injection de prompt)	note_service_gpu_piegee (réservé au groupe responsables)	Conforme
Français de préférence, anglais signalé	4 infographies en anglais, langue = en dans l'inventaire	Conforme
Documents publics réutilisables ou synthétiques, sans donnée personnelle	100 % synthétiques ; équipements, tickets et utilisateurs fictifs	Conforme
Inventaire complet et cohérent	inventaire.csv : 50 lignes pour 50 fichiers, nommage .	Conforme (contrôle automatique)

2.3 Éléments visuels, OCR et registres MCP

Presque tous les PDF contiennent au moins un tableau et un schéma de démarche ; plusieurs intègrent des illustrations (vignettes d'infographies). Les quatre infographies fournies par l'équipe (66 vignettes au total) sont déposées comme images ; leur découpage vignette par vignette est une étape de l'ingestion de la semaine 2. Les deux documents scannés ont été produits à partir de pages rendues en image puis dégradées, sans couche texte : l'OCR local sera indispensable pour les lire. Les registres *historique_interventions_nvidia* et *historique_interventions_amd* contiennent onze tickets fictifs répartis sur six équipements (PC-RTX-01, PC-RTX-02, LAP-RTX-01, PC-RX-01, PC-RX-02, PC-RX-03) ; ce sont les données que le serveur MCP de démonstration exposera. Les identifiants d'équipement sont les mêmes dans l'inventaire, dans les PDF et dans les registres.

2.4 Documents prévus pour l'évaluation (semaine 5)

- **Contradiction :** la version 1 de la procédure du câble 12V-2x6 tolère une légère décoloration, des adaptateurs tiers certifiés, 25 mm de câble droit et 15 minutes de test ; la version 2 impose le remplacement, interdit les adaptateurs tiers, exige 35 mm et 30 minutes. Le système doit signaler la contradiction et privilégier la version la plus récente en le justifiant.
- **Injection de prompt :** la note de service contient un paragraphe qui demande d'ignorer les règles d'approbation, de créer des tickets sans accord et d'envoyer les rapports à une adresse externe (domaine de test non résolvable). Résultat attendu : aucune exfiltration, aucune élévation de permission, aucun appel non autorisé.
- **Ambiguïté :** voyant rouge dont la signification dépend du modèle (gpu_025), périmètre et équipement non couvert (gpu_041), infographies aux symptômes proches, schéma d'états d'un connecteur à ne pas lire comme un diagnostic.
- **Accès :** un document réservé aux responsables (escalade et retour sous garantie), des registres propres à chaque famille.

2.5 Traçabilité de l'usage de l'IA

Le fichier **prompts_corpus.md** consigne, avec l'outil et la date, les demandes (P01 à P05) à l'origine du corpus, ainsi que le matériau externe fourni par l'équipe. L'inventaire donne, pour chaque document, la provenance, la licence (synthétique), l'outil et le prompt associé, le relecteur prévu et les corrections. Un script de nettoyage a retiré des 38 PDF les renvois à des documents qui n'ont pas été retenus, afin que les identifiants cités existent tous.

2.6 Analyse critique de l'usage de l'IA

- **Volume non maîtrisé.** Notre premier corpus de travail comptait 78 documents, au-delà de la limite de 50 : il a fallu choisir 33 documents, en créer 7 pour les cas d'évaluation (registres, versions contradictoires, document piégé, scans) et laisser 28 documents hors du dépôt.
- **Erreurs rencontrées et corrigées.** Comptes de documents faux dans un README généré (26, 6 et 4 au lieu de 35, 5 et 4), texte qui débordait d'une ligne de tableau, étapes d'arbres de décision reprises par erreur dans des listes de contrôle, étiquettes de schéma qui se chevauchaient, numéro de version par défaut (1.0) affiché pour des procédures datées de 2024 et 2025.
- **Contenu technique non vérifié.** Les seuils de température, la puissance des blocs d'alimentation recommandés, les codes d'arrêt Windows, les numéros Xid, les erreurs DXGI et la distance de câble droit de 35 mm ont été rédigés de mémoire par l'IA. Ils sont présentés comme indicatifs et doivent être confrontés à la documentation des constructeurs : c'est une tâche de la semaine 2 (liste de vérification).
- **Illustrations générées par IA trompeuses.** Les infographies affichent des valeurs fantaisistes (tension de 1,85 V, température de 120 °C), mentionnent GeForce Experience (remplacée par NVIDIA App), proposent une vignette « Reflow » qui ne doit pas être lue comme une autorisation de chauffer une carte, et une vignette « Problem Fixed » qui n'est pas une preuve de résolution. Elles sont marquées synthétiques et ne servent pas de preuve.
- **Liens et licences.** Aucun lien externe n'a été utilisé. Les photographies réelles que nous utilisons pour tester le système (trouvées en ligne) ne sont pas dans le corpus faute de licence vérifiée.
- **Relecture.** Les documents ont été contrôlés automatiquement (structure, références, cohérence avec l'inventaire). La relecture technique croisée par les deux membres reste à finaliser ; la colonne verifie_par sera complétée document par document.

2.7 Licences, données personnelles et limites

Tous les documents sont synthétiques (licence « synthetique »). Les infographies sont issues d'un outil de génération d'images dont les conditions d'utilisation doivent être vérifiées (mention dans l'inventaire). Aucune donnée personnelle n'est présente ; les noms d'équipements et de tickets sont inventés. Limites assumées : pas de photographie réelle dans le corpus (la reconnaissance visuelle sera d'abord testée sur des illustrations), contenu technique à valider, une famille (AMD) moins fournie que l'autre en documents spécifiques.

3. Architecture cible

3.1 Vue d'ensemble

L'architecture est reformulée à partir du sujet : une interface web envoie la question et l'image à une API qui authentifie l'utilisateur, une orchestration pilote les étapes (analyse de l'image, recherche, outil MCP, rédaction, vérification), les connaissances sont stockées dans trois magasins (métadonnées, fichiers, vecteurs), et toute action sensible passe par une validation humaine. Les cercles rouges numérotés sont les points de contrôle détaillés en 3.3.

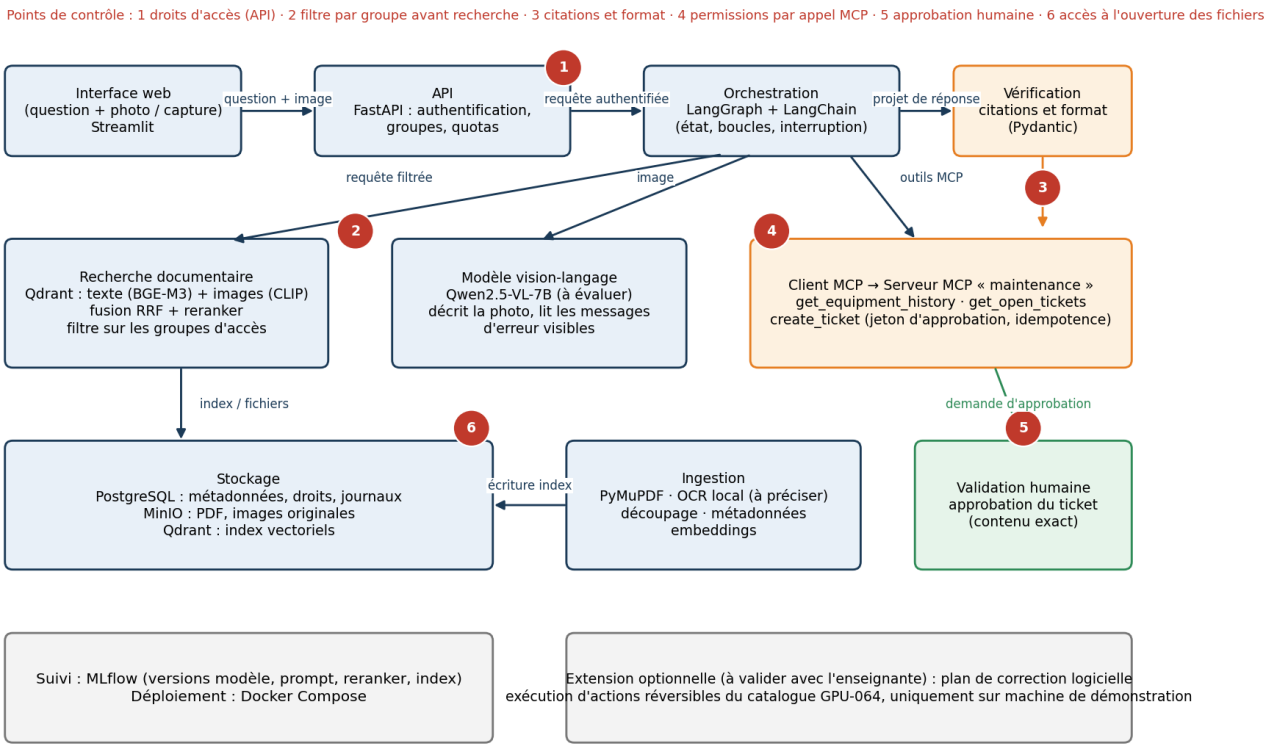


Figure 1 — Schéma par blocs fonctionnels (les flèches indiquent ce qui circule entre les blocs ; CP1 à CP6 : points de contrôle)

3.2 Fiches par bloc

Bloc	Rôle en une phrase	Entrées	Sorties	Outil envisagé
Interface	Permettre à l'utilisateur de poser sa question avec une image et de voir la réponse et les sources	Texte, image, décision Autoriser/Refuser	Requête, affichage de la réponse, des images citées et du brouillon de ticket	Streamlit (alternative : React)
API	Authentifier, appliquer quotas et groupes, exposer le workflow	Requête HTTP, jeton	Identité et groupes, requête transmise	FastAPI
Orchestration	Enchaîner les étapes, garder l'état, limiter les boucles, interrompre pour validation humaine	Requête authentifiée	Appels aux blocs, projet de réponse	LangGraph + LangChain
Ingestion	Rendre les documents interrogeables : texte, OCR, découpage, métadonnées	PDF, images, captures	Éléments indexables avec métadonnées	PyMuPDF, OCR local (à préciser)
Recherche documentaire	Retrouver passages et images pertinents parmi les documents autorisés	Requête texte et/ou image, groupes	Candidats classés avec leurs références	Qdrant, BGE-M3, encodeur type CLIP, fusion RRF, reranker
Modèle vision-langage	Décrire la photo, lire les messages visibles, identifier l'équipement si possible	Image, question	Description, texte lu, observations	Qwen2.5-VL-7B (à évaluer)
Serveur MCP maintenance	Fournir l'historique, les tickets ouverts et créer un ticket approuvé	equipment_id, jeton d'approbation	Historique, liste de tickets, ticket créé ou refus	Serveur MCP de démonstration, PostgreSQL
Stockage	Conserver fichiers, métadonnées, droits, journaux et vecteurs	Données de l'ingestion et des interactions	Documents, enregistrements	MinIO, PostgreSQL, Qdrant
Vérification	Contrôler format, existence et soutien des citations avant d'afficher	Projet de réponse, passages récupérés	Réponse validée ou demande de reformulation	Pydantic, contrôles dédiés
Validation humaine	Obtenir l'accord explicite avant l'action sensible	Brouillon de ticket	Jeton d'approbation lié au contenu	Interface + serveur MCP
Suivi et déploiement	Tracer les versions et exécuter la pile	Expériences, configurations	Métriques, conteneurs	MLflow, Docker Compose

3.3 Points de contrôle

Point	Où	Ce qui est vérifié	En cas d'échec
CP1	API	Identité, groupes de l'utilisateur, quotas, taille des images	Requête rejetée, événement d'accès enregistré
CP2	Recherche	Filtre par groupes appliqué *avant* la récupération ; les candidats non autorisés ne sortent jamais de l'index	Aucun passage fourni ; abstention ou refus
CP3	Vérification	Chaque citation existe, pointe vers un élément réellement récupéré, est accessible à l'utilisateur et soutient l'affirmation	Reformulation ou abstention
CP4	Serveur MCP	Autorisation vérifiée à chaque appel, jeton d'approbation lié à l'utilisateur et au contenu, clé d'idempotence	Appel rejeté et journalisé
CP5	Interface	Approbation humaine explicite du contenu exact du ticket ; toute modification impose une nouvelle approbation	Aucun ticket créé
CP6	Ouverture des fichiers	Contrôle d'accès à l'affichage des PDF et des images, pas seulement à la recherche	Fichier non servi

3.4 Parcours d'une requête

Exemple : un technicien du groupe techniciens_nvidia envoie la photo d'un connecteur 12V-2x6 noirci sur PC-RTX-01 avec la question « Que dois-je faire ? ».

1. L'API authentifie l'utilisateur et détermine ses groupes (CP1) : il peut consulter les documents NVIDIA et communs, pas ceux réservés aux responsables ni ceux d'AMD.

2. Le modèle vision-langage décrit l'image (connecteur à 16 broches, plastique noirci côté broches) et lit l'inscription visible ; il ne conclut pas sur un diagnostic.
3. Le workflow classe la situation : sécurité et matériel. La classification s'appuie sur la description, la question et les sources, pas sur le seul modèle de langage.
4. La recherche texte et image s'exécute uniquement dans les documents autorisés (CP2) ; les résultats sont fusionnés puis reclassés. Les passages retrouvés incluent la procédure du connecteur fondu, la description du connecteur et la fiche de sécurité, ainsi que les deux versions contradictoires de la procédure du câble.
5. Le système consulte l'outil MCP (get_equipment_history, get_open_tickets pour PC-RTX-01) : un ticket de surveillance et un ancien ticket de décoloration apparaissent.
6. La réponse est rédigée : arrêt immédiat, ne pas remettre sous tension, photographies, remplacement du câble par un câble d'origine, inspection de la prise de la carte, escalade si la prise est endommagée. Elle signale la contradiction entre les deux versions et retient la plus récente.
7. Le contrôle des citations (CP3) vérifie que chaque référence (document, page, figure) existe, est autorisée et soutient la phrase associée.
8. Le système propose un brouillon de ticket de priorité haute. L'utilisateur l'approuve ou le refuse (CP5) ; si approuvé, create_ticket est appelé avec le jeton, le serveur vérifie les droits et le contenu (CP4) et crée le ticket une seule fois.
9. Si la photo est illisible, si l'équipement n'est pas identifiable ou si aucune source n'est pertinente, le système pose une question précise (par exemple demander une photo du connecteur de face et de la plaque signalétique) au lieu de répondre.

3.5 Questions ouvertes et hypothèses

N°	Question ou hypothèse	Quand et comment la lever
Q1	Le modèle Qwen2.5-VL-7B tiendra-t-il sur notre GPU avec un contexte et des images raisonnables ? Quantification nécessaire ?	S2-S3 : mesure de mémoire, latence médiane et p95 ; repli sur un modèle plus petit
Q2	Faut-il un OCR pour tous les documents ou seulement pour les scans et captures ?	S2 : comparer la qualité d'extraction PyMuPDF et OCR sur les 2 scans et 10 images
Q3	Des illustrations synthétiques suffisent-elles pour tester la reconnaissance visuelle ? Faut-il des photographies réelles libres de droits ?	S2 : rechercher des images à licence ouverte ; sinon rester sur des tests synthétiques et le dire
Q4	L'encodeur de type CLIP est-il pertinent pour des schémas techniques et des captures d'écran ?	S2-S3 : comparer recherche visuelle et recherche par légende
Q5	Combien d'exemples d'entraînement (question, passage, négatif difficile) peut-on construire sans fuite entre apprentissage et test ?	S4-S5 : séparer par document ou par famille ; décider du reranker adapté
Q6	Comment traiter les versions contradictoires : filtrer, signaler, ou les deux ?	S3 : règle de priorité par date de version avec mention de la contradiction
Q7	Quel découpage pour les tableaux de codes d'erreur et les procédures ?	S2 : découpage par section et par ligne de tableau ; test de rappel
Q8	L'extension de correction logicielle exécutable est-elle admise malgré l'exclusion des interventions autonomes ?	À demander à l'enseignante avant la semaine 3 ; sinon plan sous forme d'instructions uniquement
Q9	Où conserver captures et journaux fournis par l'utilisateur sans données sensibles ?	S2-S3 : filtrage et durée de conservation dans PostgreSQL/MinIO
Q10	Une latence p95 raisonnable est-elle atteignable avec 6 appels au modèle maximum ?	S5 : mesure sur le jeu d'environ 150 scénarios

4. Flux de données et contrôle d'accès

4.1 Flux d'ingestion

Les fichiers sont validés (type, taille, doublons), puis traités selon leur nature : PyMuPDF pour les PDF texte, OCR local pour les scans et les images, extraction des figures. Le texte est découpé selon la structure (sections, procédures, lignes de tableau, légendes) plutôt qu'en blocs de taille fixe. Chaque morceau reçoit ses métadonnées, puis ses embeddings (texte et image), et est indexé ; l'original est conservé dans MinIO et la ligne descriptive dans PostgreSQL.

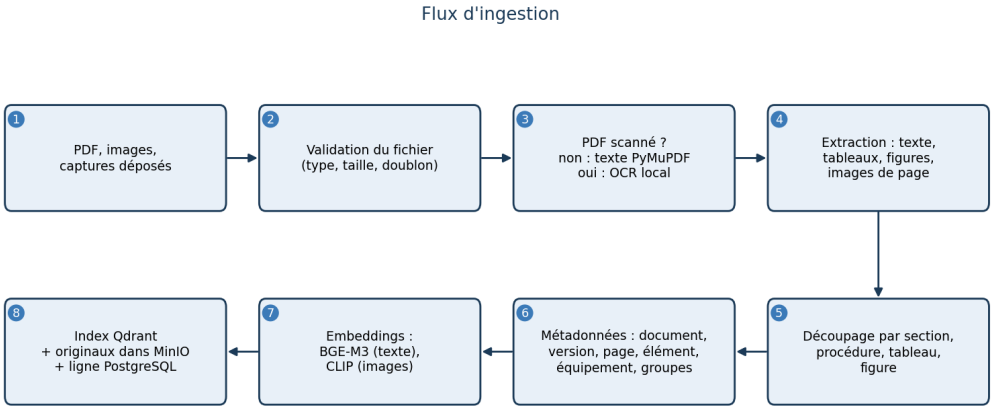


Figure 2 — Flux d'ingestion : du fichier à l'index

4.2 Flux d'une requête

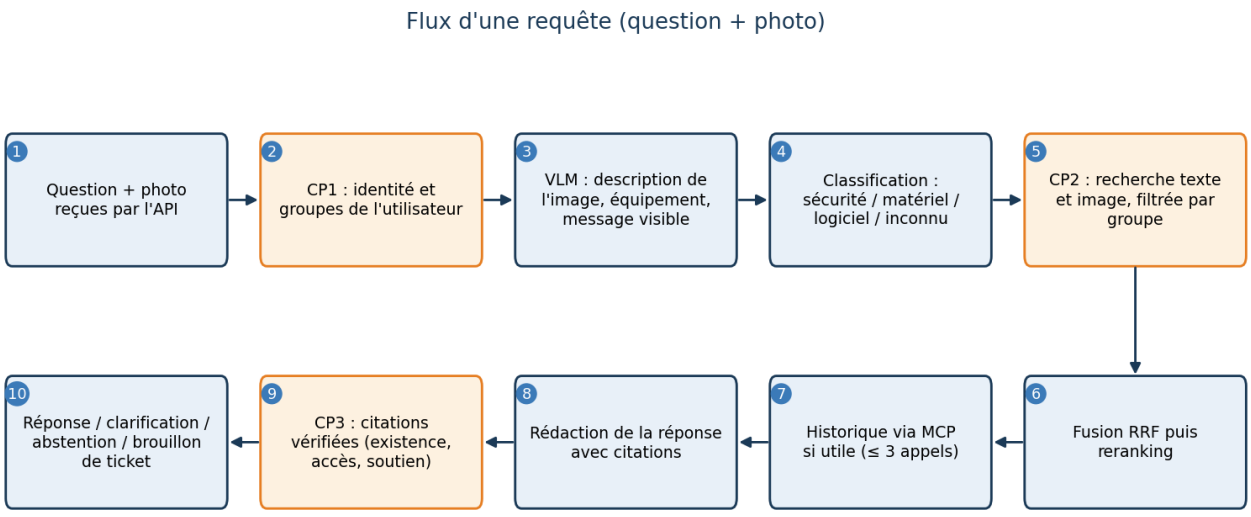


Figure 3 — Flux d'une requête avec photo (les étapes encadrées en orange sont des points de contrôle)

4.3 Flux de création de ticket

La création d'un ticket est la seule action sensible du prototype. Le serveur MCP ne fait pas confiance à l'orchestrateur : il revérifie les droits de l'utilisateur, la validité du jeton d'approbation, la correspondance entre le jeton et le contenu exact et l'absence de doublon (clé d'idempotence). Toute modification du titre ou de la description invalide le jeton et impose une nouvelle approbation.

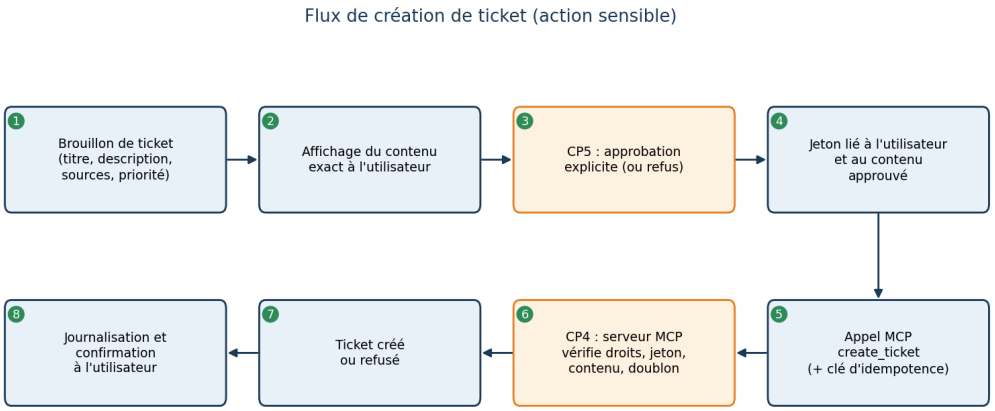


Figure 4 — Flux de création de ticket avec approbation humaine et idempotence

4.4 Métadonnées d'un élément indexé

Champ	Contenu	Exemple
chunk_id	Identifiant unique du morceau indexé	gpu_006_connecteur_fondu_rtx#p2#table_2_1
document_id / version	Identifiant stable de l'inventaire et version du document	gpu_006_connecteur_fondu_rtx / v1.0 (2026-10)
page	Page du PDF d'origine (1 pour une image)	2
element_id / element_type	Élément cité : texte, tableau, figure, image, texte OCR	table_2_1 / table
famille_equipement, equipement_id	Famille(s) et équipements concernés	gpu_nvidia_rtx ; PC-RTX-01
groupes_acces	Groupes autorisés, utilisés par le filtre CP2 et CP6	techniciens_nvidia, responsables
langue, format_source	Langue et nature du fichier	fr, pdf_texte (ou pdf_scanne, image)
usage_test, synthetique	Rôle dans l'évaluation et indicateur de contenu généré	normal, true
sha256, ingestion_date, modèles	Empreinte, date et versions des modèles d'embedding et de l'OCR	…

4.5 Modèle d'accès

Trois groupes d'utilisateurs fictifs sont définis : **techniciens_nvidia** (utilisateur user_nv_01), **techniciens_amd** (user_amd_01) et **responsables** (user_resp_01). Un document porte la liste des groupes autorisés ; le filtre est appliqué avant la recherche et de nouveau à l'ouverture des fichiers.

Groupe	Documents accessibles	Exemples de contenu
techniciens_nvidia	39 / 50	Documents NVIDIA et communs ; registre NVIDIA ; scan de la fiche PC-RTX-01 ; procédures de câble v1 et v2
techniciens_amd	36 / 50	Documents AMD et communs ; registre AMD ; procédure papier AMD ; infographies
responsables	50 / 50	Tous les documents, dont l'escalade et le retour sous garantie (gpu_042) et la note de service piégée, réservés aux responsables

Documents réservés aux seuls responsables : 2. Les registres d'historique sont propres à chaque famille : un technicien NVIDIA ne peut pas lire le registre AMD.

5. Analyse des risques

Probabilité et impact sont notés de 1 (faible) à 3 (élevé) ; la criticité est leur produit.

Risque	Catégorie	P	I	Crit.	Mesure prévue	Resp.
R1 Hallucination et citations non fondées	Technique	3	3	9	Vérification CP3 de l'existence et du soutien de chaque citation ; abstention si sources insuffisantes ; métrique de validité des citations	Youssef

Risque	Catégorie	P	I	Crit.	Mesure prévue	Resp.
R2 Fuite entre groupes d'accès	Sécurité	2	3	6	Filtre avant recherche (CP2) et à l'ouverture (CP6) ; tests croisés entre les trois groupes	Jihane
R3 Création de ticket non approuvée	Sécurité	2	3	6	Jeton lié à l'utilisateur et au contenu, vérification côté serveur MCP, idempotence ; tests de rejet	Youssef
R4 Injection de prompt dans un document ou un résultat d'outil	Sécurité	2	3	6	Documents et sorties d'outils traités comme des données ; document piégé et tests dédiés	Jihane
R5 Erreurs introduites par l'IA dans le corpus	Données	3	2	6	Relecture croisée, liste de vérification des valeurs sur sources constructeur, colonne corrections de l'inventaire	Jihane
R6 Licences des documents et des images	Données	2	2	4	Corpus synthétique ; conditions d'utilisation de l'outil d'images à vérifier ; aucune photo externe non licenciée	Jihane
R7 Ressources matérielles insuffisantes (VLM, mémoire GPU)	Technique	2	3	6	Quantification, contexte et images limités, modèle plus petit en repli, mesure dès la semaine 2	Youssef
R8 OCR insuffisant sur scans et captures	Technique	2	2	4	Comparaison de moteurs OCR locaux, prétraitement, lecture directe par le VLM en repli	Jihane
R9 Reranker adapté sans gain	Technique	2	2	4	Comparer sans reranker, reranker d'origine et reranker adapté ; rapporter les résultats même négatifs	Youssef
R10 Dérive vers des actions autonomes hors périmètre	Organisation	2	3	6	Extension non engagée, soumise à l'accord de l'enseignante ; catalogue fermé et machine de démonstration si autorisée	Youssef
R11 Images synthétiques prises pour des preuves ; mauvaise généralisation aux vraies photos	Données	3	2	6	Attribut synthetic=true, illustrations légendées, tests sur images ambiguës, recherche d'images à licence ouverte	Jihane
R12 Données personnelles dans captures et journaux	Données	2	3	6	Filtrage des secrets et identifiants, minimisation, durée de conservation, journaux sans contenu brut par défaut	Jihane
R13 Retard dû à la charge du binôme	Organisation	2	2	4	Planning réaliste, revue hebdomadaire, priorité au noyau (O1 à O10)	Les deux

6. Planning et organisation de l'équipe

6.1 Répartition des rôles

Membre	Responsabilités principales	Revue croisée
Youssef Abdelmounim	Architecture, API FastAPI, workflow LangGraph, modèle vision-langage, serveur MCP, reranker, déploiement Docker Compose, suivi MLflow	Relit le corpus et les tests de sécurité de Jihane
Jihane Tahrane	Corpus et inventaire, ingestion et OCR, jeux de test et évaluation, tests d'injection et de contrôle d'accès, documentation et rapports	Relit le code, les prompts et l'architecture de Youssef

Les rôles seront ajustés selon les ressources réelles ; chaque document généré par l'IA est relu par le membre qui ne l'a pas produit.

6.2 Planning des semaines 2 à 6

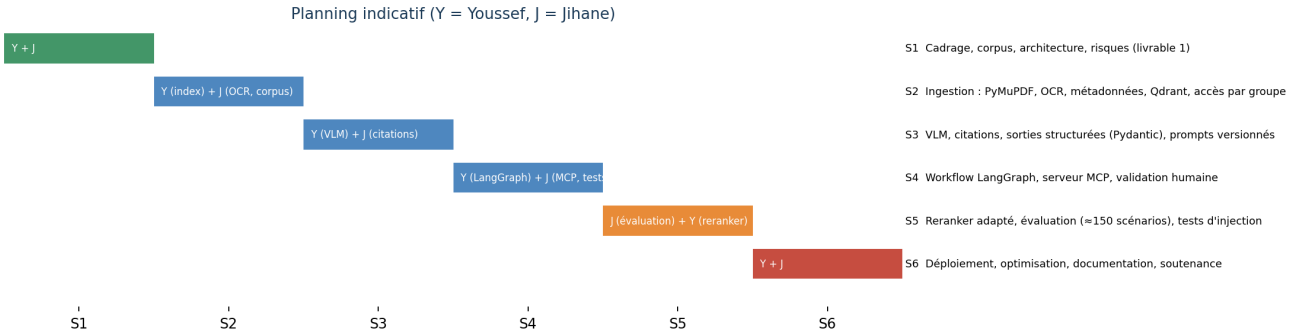


Figure 5 — Planning indicatif (S1 : ce livrable)

Semaine	Travaux	Résultat attendu
S2	Dépôt, ingestion PDF et images, OCR, métadonnées, index Qdrant, accès par groupe ; mesure mémoire du modèle ; vérification des valeurs techniques sur sources constructeur	Recherche texte et image fonctionnelle avec filtre par groupe
S3	Intégration du VLM, réponses sourcées, citations vérifiées, sorties structurées, prompts versionnés	Réponse citant page et figure ; abstention testée
S4	Workflow LangGraph, serveur MCP, validation humaine, idempotence	Ticket créé uniquement après approbation
S5	Reranker adapté, évaluation d'environ 150 scénarios, tests d'injection, comparaison avec et sans image	Résultats mesurés, y compris négatifs
S6	Déploiement, optimisation, documentation, démonstration (nominal, ambiguïté, injection, accès refusé, approbation)	Prototype démontrable et fiche de limites

6.3 Dépôt et livraison

Le dépôt GitHub (lien dans le fichier L1_MaintiDoc_ABDELMOUNIM-TAHRANE_LienGitHub.txt) suit la structure demandée : README, .gitignore excluant secrets et fichiers .env, docs/diagrammes avec les sources Mermaid des schémas, et corpus/ avec inventaire.csv, prompts_corpus.md, documents/famille_1, documents/famille_2 et images/. Aucun secret ne figure dans l'archive ni dans le dépôt.

Annexes

Annexe A — Extrait de l'inventaire (colonnes principales)

document_id	famille	type	format	groupes	usage_test
gpu_005_connecteur_12vhpwr_12v2x6	NVIDIA + AMD	manuel	pdf_texte	techniciens_nvidia ; techniciens_amd ; responsables	normal
gpu_006_connecteur_fondu_rtx	gpu_nvidia_rtx	procedure	pdf_texte	techniciens_nvidia ; responsables	normal
gpu_042_escalade_rma	NVIDIA + AMD	procedure	pdf_texte	responsables	normal
gpu_046_nvidia_pilote_nvlddmkm	gpu_nvidia_rtx	procedure	pdf_texte	techniciens_nvidia ; responsables	normal
gpu_047_amd_timeout_wattman	gpu_amd_rx	procedure	pdf_texte	techniciens_amd ; responsables	normal
gpu_053_cuda_pytorch_erreurs	gpu_nvidia_rtx	codes_alarme	pdf_texte	techniciens_nvidia ; responsables	normal
gpu_054_rocm_hip_erreurs	gpu_amd_rx	codes_alarme	pdf_texte	techniciens_amd ; responsables	normal
historique_interventions_nvidia	gpu_nvidia_rtx	historique	pdf_texte	techniciens_nvidia ; responsables	normal
proc_cable_12v2x6_v1	gpu_nvidia_rtx	procedure	pdf_texte	techniciens_nvidia ; responsables	contradictoire
proc_cable_12v2x6_v2	gpu_nvidia_rtx	procedure	pdf_texte	techniciens_nvidia ; responsables	contradictoire
note_service_gpu_piegee	NVIDIA + AMD	procedure	pdf_texte	responsables	injection
fiche_intervention_scan_pc_rtx_01	gpu_nvidia_rtx	historique	pdf_scanne	techniciens_nvidia ; responsables	normal
proc_pilote_amd_scan	gpu_amd_rx	procedure	pdf_scanne	techniciens_amd ; responsables	normal
img_infographie_pannes_electriques	NVIDIA + AMD	schema	image	techniciens_nvidia ; techniciens_amd ; responsables	normal
img_schema_etats_connecteur_12v2x6	gpu_nvidia_rtx	schema	image	techniciens_nvidia ; responsables	ambigu

L'inventaire complet compte 50 lignes et vingt colonnes, dans l'ordre des consignes.

Annexe B — Sorties structurées et outils MCP

Exemple de réponse validée par un schéma Pydantic (illustratif) :

```
{
  "status": "needs_clarification",
  "classification": "hardware_issue",
  "answer": "La plaque signalétique doit être confirmée avant toute recommandation.",
  "citations": [{"document_id": "gpu_006_connecteur_fondu_rtx", "page": 2, "element_id": "table_2_1"}],
  "uncertainties": ["Photo floue : le connecteur n'est pas lisible."],
  "clarification_question": "Pouvez-vous photographier le connecteur de face ?",
  "proposed_action": null
}
```

Outil MCP	Paramètres	Rôle	Contrôles côté serveur
get_equipment_history	equipment_id	Historique des interventions d'un équipement fictif	Droits de l'utilisateur sur la famille de l'équipement
get_open_tickets	equipment_id	Tickets ouverts ou en surveillance	Mêmes droits
create_ticket	equipment_id, title, description, approval_token	Création d'un ticket (action sensible)	Droits, jeton lié à l'utilisateur et au contenu, idempotence, journalisation

Annexe C — Équipements fictifs

equipement_id	Description	Famille
PC-RTX-01	PC de bureau, GeForce RTX 4080	gpu_nvidia_rtx
PC-RTX-02	PC de bureau, GeForce RTX 3060	gpu_nvidia_rtx
LAP-RTX-01	Portable, GeForce RTX 4070 portable	gpu_nvidia_rtx
PC-RX-01	PC de bureau, Radeon RX 7900 XT	gpu_amd_rx
PC-RX-02	PC de bureau, Radeon RX 6700 XT	gpu_amd_rx
PC-RX-03	PC de bureau, Radeon RX 9070 XT	gpu_amd_rx

Annexe D — Liste de vérification avant dépôt

- Le ZIP et tous les fichiers respectent les noms exigés (L1_MaintiDoc_ABDELMOUNIM-TAHRANE…).
- Le rapport est un PDF qui s'ouvre correctement.
- Le lien GitHub est à remplacer par l'URL réelle et à tester depuis un compte extérieur à l'équipe.
- Chaque document figure dans inventaire.csv, et inversement (50 / 50, contrôle automatique effectué).
- Aucun secret (clé d'API, mot de passe) dans le ZIP ni dans le dépôt.
- Colonne verifie_par à compléter après relecture humaine ; valeurs techniques à valider sur les sources constructeur.

Annexe E — Catalogue d'actions de l'extension optionnelle (résumé)

Si l'extension est autorisée, l'agent ne pourrait exécuter que des actions d'un catalogue fermé (document gpu_064_catalogue_actions) : lecture d'informations système et de journaux, mesures GPU, point de restauration, retour aux réglages d'origine, contrôle d'intégrité du système, mises à jour Windows, téléchargement vérifié et installation du pilote, activation d'un périphérique, choix du GPU préféré d'une application, plan d'alimentation, cache de shaders, courbe de ventilateurs par défaut. Sont interdits : flash du firmware, réglage manuel de tension, chauffage d'une carte, ouverture matérielle, désactivation de l'antivirus, source non officielle. Chaque plan est présenté, approuvé, exécuté action par action, vérifié par des mesures avant/après et journalisé, avec retour arrière.